

FORGE ATLAS

Catalogue maître des briques IA, agents, RAG, mémoire, sécurité et infrastructure

Stack local + cloud premium - consolidation complète de la conversation

Version : 12 juillet 2026

294 entrées consolidées, incluant briques, méthodes, services internes, modèles, routes et solutions remplacées/refusées.

Règle de sélection : une nouvelle brique n'est jamais refusée uniquement parce qu'elle est similaire. Elle doit être comparée aux choix en place; la meilleure remplace l'ancienne, les deux restent uniquement si leurs rôles sont réellement complémentaires.

Important : ce document consolide les décisions prises dans la conversation. Les composants marqués « revalider » doivent faire l'objet d'une vérification officielle de version, licence, dépôt et sécurité avant installation.

1. Comment lire ce document

- ACCEPTÉ - NOYAU:** obligatoire dans l'architecture cible.
- ACCEPTÉ:** retenu avec un rôle défini et non redondant.
- ACCEPTÉ SOUS CONDITIONS / SOUS GATE:** retenu seulement avec licence, sandbox, benchmark ou approbation humaine.
- REPLACÉ:** ancien choix retiré au profit d'un composant supérieur.
- RECLASSÉ:** élément utile, mais ce n'est pas une brique : route, modèle, méthode, profil ou service interne.
- REFUSÉ APRÈS COMPARAISON:** ne surclasse pas le choix retenu pour FORGE.

Le numéro de phase indique l'ordre d'implantation. Un composant de phase 8 ne doit pas être installé avant que ses dépendances des phases 0 à 7 soient stables, observables et sauvegardées.

2. Architecture cible condensée

Utilisateurs / IDE / mobile / voix

- > OpenClaw, Open WebUI, Cursor, Cline, Claude Code, Codex, OpenCode
- > Hermes Orchestrator
- > LangGraph + Pydantic Deep Agents + Hermes Agent + workers spécialisés
- > ContextForge + OPA + Nathan Gates
- > vLLM Semantic Router + premium_cost_gate + Bifrost
- > KubeAI -> vLLM / SGLang / llama.cpp / Ollama / NVIDIA NIM
- > modèles locaux et cloud

Connaissances : Docling/Crawl4AI/Firecrawl -> LlamaIndex -> Qdrant/Neo4j/Sourcegraph

Mémoire : MemOS + Graphiti + Projectmem -> Context Pack Compiler -> EverOS miroir Git

Observabilité : OpenTelemetry Collector -> Langfuse/Prometheus/Grafana/Loki/Tempo/OpenMeter

Livraison : Git -> Harness -> Argo CD -> K3s

3. Ordre d'implantation - ce qui doit être fait en premier

Phase	Objectif	Briques et résultat attendu
0	Assainissement et autorité	Inventaire, sauvegarde, current-state.yml, ledgers, canons, Ansible, Terraform/OpenTofu, blueprint Clean Foundation.
1	Socle infrastructure et données	K3s, réseau, Traefik, MetalLB, Cilium, identité, secrets, PostgreSQL, Qdrant, Neo4j, Valkey, NATS, MinIO, backups.
2	Observabilité et preuve	OpenTelemetry Collector, Langfuse, Prometheus, Grafana, Loki, Tempo, OpenMeter, immudb, GPU exporters, contrôle live.
3	Serving et routage modèles	KubeAI, vLLM/SGLang/llama.cpp/Ollama/NIM, Bifrost, Semantic Router, cost gate, LMCache, routes modèles.
4	RAG et intelligence du code	Docling, Crawl4AI, Firecrawl, LlamaIndex, Tree-sitter/cAST, Qwen embeddings/rerank, Sourcegraph, OpenMetadata.
5	Mémoire agentique	Forge Memory MCP, MemOS, Graphiti, Projectmem, LangMem, Context Pack Compiler, EverOS et consolidation.
6	Orchestration et agents	Hermes Orchestrator, LangGraph, Hermes Agent, Pydantic Deep Agents, n8n, OpenHands, DeerFlow, forge-council.
7	MCP, outils et interfaces	ContextForge, MCP allowlistés, OpenClaw, Open WebUI, cockpits IDE/CLI, command center read-only.
8	Guardrails et sandbox	OPA complet, Lakera/GA/Llama Guard, NeMo, LlamaFirewall, Presidio, gVisor/Kata, Tetragon.
9	Livraison, qualité et gouvernance	Harness, Argo CD, StackGen, BMAD, Spec Kit, Superpowers, TDAD, Promptfoo, Ragas, DeepEval, signatures.

Phase	Objectif	Briques et résultat attendu
10	Applications et blueprints	Dify, Mastra, Vercel AI SDK, Atoms, Agentailor, templates Vstorm et blueprints de reset.
11	Fine-tuning et optimisation	Unsloth Studio, W&B, DSPy/GEPA, benchmarks, optimisation modèles/prompts.
12	Auto-amélioration expérimentale	DGM/HGM/RQGM/DGM-H en sandbox isolée, PR seulement, jamais d'auto-déploiement.

Comptage consolidé : Accepté 203, Refusé 64, Reclassé/Fusionné 8, Remplacé 10, Autre 9 - total 294 entrées.

4. Catalogue détaillé - une entrée par brique, méthode, modèle ou service

Les modèles et routes sont volontairement inclus à la fin pour éviter qu'ils soient de nouveau comptés comme briques installables.

4.1 Gouvernance, méthodes, skills et preuves

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
1	current-state.yml / State Ledger	Registre interne	ACCEPTÉ - NOYAU	0	Git canonique -> tous les agents et tableaux de bord	Autorité unique de l'état réel; empêche les statuts divergents et les faux DONE.	Consolidé
2	Decision Ledger	Ledger interne	ACCEPTÉ - NOYAU	0	Hermes/LangGraph -> PostgreSQL append-only	Trace décisions, alternatives, raisons, remplacements et approbations.	Consolidé
3	Proof Ledger	Ledger interne	ACCEPTÉ - NOYAU	0	CI, tests, gates -> immudb/MinIO/PostgreSQL	Lie chaque DONE à des commandes, sorties, hashes, artefacts et rollback.	Consolidé
4	Execution Ledger	Ledger interne	ACCEPTÉ	2	Langfuse/OTel -> PostgreSQL	Historique structuré des étapes, outils, modèles, coûts et résultats.	Consolidé
5	Model Ledger	Ledger interne	ACCEPTÉ	2	W&B -> catalogue des modèles	Suit versions, quantifications, configurations, benchmarks et affectations matérielles.	Consolidé
6	Artifact Ledger	Ledger interne	ACCEPTÉ	2	MinIO versionné -> Proof Ledger	Conserve rapports, logs, diffs, captures et datasets liés aux missions.	Consolidé
7	Supply-chain Ledger	Ledger interne	ACCEPTÉ	2	Cosign/Sigstore -> registre d'attestations	Conserve SBOM, signatures d'images et attestations de provenance.	Consolidé
8	IAR-E PostgreSQL Ledger	Ledger interne	ACCEPTÉ - NOYAU	0	Intent -> Action -> Result -> Evidence dans PostgreSQL	Schéma transversal pour relier intention, action, résultat et preuve.	Consolidé
9	Nathan Gates	Politique humaine	ACCEPTÉ - NOYAU	0	OPA/Hermes/Harness -> approbation Nathan	Bloque paiements, production, secrets, fiscalité, suppressions et engagements externes.	Consolidé
10	Proof-Driven Agentic SDLC	Méthodologie	ACCEPTÉ - NOYAU	0	Spec -> plan -> risque -> exécution -> preuve -> DONE	Cycle de livraison vérifiable et récupérable, adapté aux agents autonomes.	Consolidé
11	CIV Pattern	Méthodologie	ACCEPTÉ	0	Coordinateur -> implémenteur -> validateur indépendant	Empêche qu'un agent valide son propre travail.	Consolidé
12	BMAD	Méthodologie	ACCEPTÉ	9	Demande -> vision/PRD/architecture/stories -> Hermes	Structure les grands projets avant exécution.	Consolidé
13	GitHub Spec Kit	Méthodologie/ outillage	ACCEPTÉ	9	Constitution/spécifications -> BMAD/Hermes	Produit des spécifications et critères d'acceptation machine-lisibles.	Consolidé
14	Superpowers	Bibliothèque de skills	ACCEPTÉ	9	Skill Registry -> agents de développement	Fournit TDD, debugging, brainstorming, planification et revue composables.	Consolidé
15	GSD Core	Méthodologie	REFUSÉ	-	Ne pas installer	Ne surclasse pas BMAD + Spec Kit + Superpowers + l'état canonique FORGE.	Consolidé
16	TDAD	Méthodologie/ outillage tests	ACCEPTÉ - PRIORITAIRE	9	Graphe code-tests -> Harness CI -> Proof Ledger	Sélectionne les tests impactés et réduit les régressions des agents.	Consolidé
17	MetaGPT SOP	Méthodologie	ACCEPTÉ - CONCEPT	9	Rôles/SOP -> BMAD + Hermes Orchestrator	Conserve l'idée Code = SOP(Team) sans adopter le runtime MetaGPT.	Consolidé
18	RARV / Loki-like	Méthodologie	RECLASSÉ	0	Absorbé dans CIV + Proof-Driven SDLC	Bon principe de vérification, mais aucun système doctrinal parallèle.	Consolidé
19	AGENTS.md	Convention de dépôt	ACCEPTÉ - NOYAU	0	Racine de chaque dépôt -> tous les agents	Expose règles, commandes, architecture, limites et procédures propres au dépôt.	Consolidé
20	memory-bank	Convention/état Git	ACCEPTÉ	0	Un seul répertoire canonique -> agents	État lisible et versionné; ne remplace pas la mémoire runtime.	Consolidé
21	DO-NOT-FORGET / CANON	Politique canonique	ACCEPTÉ	0	Git -> Context Pack Compiler -> agents	Contraintes non négociables et objectifs durables.	Consolidé
22	ACTIVE_MEMORY_LOCKED_V5	Snapshot historique	ACCEPTÉ - ARCHIVE	0	Stockage immuable; jamais état courant	Préserve une référence historique sans contaminer l'état actif.	Consolidé
23	audit-canon-skill	Skill interne	ACCEPTÉ - NOYAU	0	Début de chaque cycle d'audit	Relit canon initial, canon courant et état réel avant	Consolidé

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
24	no-fake-done-check	Skill interne	ACCEPTÉ - NOYAU	9	Avant commit/PR/DONE -> Harness + Proof Ledger	toute modification. Refuse tout DONE sans tests, preuves et artefacts suffisants.	Consolidé
25	forge-quality-phase-a-skill	Skill interne	ACCEPTÉ	9	Agents -> lint/tests/security -> Harness	Gate qualité standard avant commit, PR et livraison.	Consolidé
26	rag-retrieve-context	Skill interne	ACCEPTÉ	4	ContextForge -> Qdrant/Sourcegraph/Neo4j	Récupère un contexte traçable et cité avant raisonnement ou modification.	Consolidé
27	Find Skills / Skill Registry	Registre de skills	ACCEPTÉ	6	Hermes -> registre allowlisté/versionné	Charge seulement les skills nécessaires et contrôle versions/hashees.	Consolidé
28	skills-runtime-selection	Routeur interne	ACCEPTÉ	6	Hermes Orchestrator -> Skill Registry	Sélectionne les skills selon tâche, risque, modèle et cockpit.	Consolidé
29	Karpathy Guidelines	Skill communautaire	ACCEPTÉ	9	Skill Registry -> agents code	Impose simplicité, hypothèses explicites, changements chirurgicaux et vérification.	Consolidé
30	Matt Pocock Skills	Skills techniques	ACCEPTÉ	9	Skill Registry -> agents TypeScript	Complète Superpowers avec des pratiques ciblées et composables.	Consolidé
31	NVIDIA-style skills / agency-persona-conversion	Pattern non identifié	REFUSÉ	-	Ne pas installer	Aucun artefact officiel clairement vérifié; les personas sont gérés par Hermes.	Consolidé
32	ACE Context Engineering	Méthodologie	ACCEPTÉ	5	Context Pack Compiler + mémoire	Gouverne sélection, évolution, provenance et budget du contexte.	Consolidé
33	Context Pack Compiler	Service interne	ACCEPTÉ - NOYAU	5	RAG + mémoire + politiques -> paquet de contexte	Compile sources, hashes, fraîcheur, permissions et budget de tokens par mission.	Consolidé
34	Sleep-time Consolidation	Processus mémoire	ACCEPTÉ	5	Planificateur nocturne -> rapport -> gate	Détecte doublons, contradictions et souvenirs obsolètes; correction sous contrôle.	Consolidé
35	DSPy	Optimisation de programmes LLM	ACCEPTÉ - SPÉCIALISÉ	11	Jeux d'éval -> optimisation de prompts/pipelines	Optimise de façon mesurée les extracteurs, rerankers et programmes LLM.	Consolidé
36	GEPA	Optimisation	ACCEPTÉ - SPÉCIALISÉ	11	DSPy/benchmarks -> candidats de prompts	Complète DSPy pour l'optimisation contrôlée, jamais en auto-déploiement.	Consolidé

4.2 Orchestration, agents et interfaces

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
37	Hermes Orchestrator	Control plane agentique	ACCEPTÉ - NOYAU	6	Interfaces -> Hermes Orchestrator -> LangGraph	Distribue missions, rôles, budgets, modèles, skills et gates.	Consolidé
38	Hermes Agent	Agent autonome	ACCEPTÉ - NOYAU	6	Hermes Orchestrator -> worker Hermes -> outils/mémoire	Agent principal pour compétences, apprentissage et exécution contrôlée.	Consolidé
39	LangGraph	Orchestrateur durable	ACCEPTÉ - NOYAU	6	Hermes -> graphes/checkpoints/HITL -> workers	Assure reprise, état durable, branches, interruptions humaines et streaming.	Consolidé
40	n8n	Automatisation métier	ACCEPTÉ - NOYAU	6	Événements/API -> workflows déterministes -> services	Gère webhooks, horaires, intégrations SaaS, ETL léger et notifications.	Consolidé
41	OpenClaw	Interface/agent personnel	ACCEPTÉ	7	Mobile/voix/messaging -> Hermes/Bifrost	Interface personnelle multicanal; aucune permission directe privilégiée.	Consolidé
42	Open WebUI	Interface de conversation	ACCEPTÉ	7	Utilisateur -> Open WebUI -> Bifrost/Hermes	Chat, comparaison et administration légère sans contourner le gateway.	Consolidé
43	Dify	AI app builder low-code	ACCEPTÉ - RÔLE LIMITÉ	10	Dify -> Bifrost/ContextForge -> services FORGE	Prototypes et applications IA low-code; ne remplace pas LangGraph/n8n.	Consolidé
44	Mastra	Framework agentique TypeScript	ACCEPTÉ	10	Apps Node/Next -> Mastra -> ContextForge/Bifrost	Framework code-first TypeScript pour workflows, agents et outils applicatifs.	Consolidé
45	Vercel AI SDK	SDK TypeScript	ACCEPTÉ - NOYAU TS	10	React/Next.js -> AI SDK -> Bifrost	Standardise streaming, sorties structurées, outils et interfaces IA TypeScript.	Consolidé
46	Agentailor	Blueprints/générateur MCP	ACCEPTÉ - BLUEPRINT	10	Templates -> nouveaux services LangGraph.js/MCP	Accélère la création d'applications et serveurs MCP sans devenir runtime central.	Consolidé
47	Vercel Eve	Runtime agentique TypeScript	REFUSÉ	-	Ne pas installer	Ne surclasse pas Mastra pour maturité, liberté de déploiement et contrôle du runtime.	Consolidé
48	Pydantic Deep Agents (Vstorm)	Harness agentique Python	ACCEPTÉ - PRINCIPAL	6	LangGraph -> Pydantic Deep Agents -> ContextForge	Sous-agents typés, skills, checkpoints, mémoire et sandboxes; remplace DeepAgents LangChain.	Consolidé
49	LangChain DeepAgents	Harness agentique	REPLACÉ	-	Remplacé par Pydantic Deep Agents	Le choix Pydantic est plus cohérent avec typage strict et gouvernance FORGE.	Consolidé
50	Vstorm Full-Stack AI Agent Template	Blueprint applicatif	ACCEPTÉ - BLUEPRINT	10	Template -> FastAPI/Next.js -> stack FORGE	Base de départ pour applications IA; importer seulement les patterns utiles.	Consolidé
51	OpenHands	Agent logiciel sandboxé	ACCEPTÉ SOUS CONDITIONS	6	Hermes -> OpenHands sandbox -> Git/Harness	Worker autonome pour dépôts complets; sandbox à réparer et durcir avant production.	Consolidé
52	Aider	Agent CLI Git-first	ACCEPTÉ	6	Hermes ou Nathan -> Aider -> branche Git	Rapide pour petites corrections et commits contrôlés.	Consolidé
53	Cline	Agent IDE	ACCEPTÉ	7	IDE -> Cline -> ContextForge/Bifrost	Exécution fichiers/terminal/navigateur sous politiques et gateway uniques.	Consolidé
54	Cursor	Cockpit IDE	ACCEPTÉ	7	Utilisateur -> Cursor -> agents/gateways	Cockpit principal de supervision; pas orchestrateur central.	Consolidé
55	VSCodium	Cockpit IDE open source	ACCEPTÉ	7	VSCodium/Cline -> ContextForge/Bifrost	Alternative ouverte pour travailler sans télémétrie Microsoft par défaut.	Consolidé
56	Claude Code	Cockpit/agent CLI cloud	ACCEPTÉ - PREMIUM	7	Claude Code -> ContextForge/Bifrost -> infra	Cerveau/juge possible, mais délégation maximale au stack et gates FORGE.	Consolidé
57	Codex CLI	Agent CLI	ACCEPTÉ	7	Codex -> ContextForge/Bifrost	Cockpit supplémentaire; mêmes politiques, outils et mémoire centralisés.	Consolidé
58	OpenCode	Agent CLI/IDE	ACCEPTÉ	7	OpenCode -> ContextForge/Bifrost	Cockpit ouvert; ne possède pas de MCP ou mémoire parallèle.	Consolidé
59	DeerFlow 2.0	Agent long-horizon	ACCEPTÉ - SPÉCIALISÉ	6	Hermes -> DeerFlow -> recherche/sandbox	Worker pour recherche profonde et missions longues; ne remplace pas LangGraph.	Consolidé
60	kagent	Agent Kubernetes	ACCEPTÉ - NOYAU K3S	7	Hermes/observabilité -> kagent read-only -> K3s	Diagnostic et exploitation Kubernetes; remédiation uniquement sous gate.	Consolidé
61	forge-council	Service interne	ACCEPTÉ	6	Hermes -> conseil acteur/critique/juge	Arbitrage complexe avec modèles indépendants;	Consolidé

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
		multi-modèles				activé seulement si nécessaire.	
62	AutoGPT Platform	Plateforme agentique	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Hermes + LangGraph + n8n + Dify + OPA pour gouvernance et K3s.	Consolidé
63	MetaGPT runtime	Framework multi-rôles	REFUSÉ	-	Ne pas installer; conserver SOP	Rôles utiles, mais runtime moins adapté et redondant avec BMAD/Hermes/LangGraph.	Consolidé
64	MetaGPT X / MGX	Plateforme antérieure	REPLACÉ	-	Remplacé par Atoms	Évolution de produit; ne pas maintenir comme brique distincte.	Consolidé
65	Atoms	Fabrique d'applications cloud	ACCEPTÉ - EXTERNE	10	Atoms -> export GitHub -> Harness/scan/tests	Création rapide de MVP/SaaS; aucune donnée sensible et tout code repasse par FORGE.	Consolidé
66	Google ADK	Framework agentique	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas LangGraph/Hermes pour le noyau local-cloud FORGE.	Consolidé
67	OpenAI Agents SDK	Framework agentique	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Sessions/handoffs/guardrails utiles, mais runtime parallèle et orientation fournisseur inutile.	Consolidé
68	CrewAI	Framework multi-agents	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas LangGraph/Hermes pour durabilité, gouvernance et intégration.	Consolidé
69	AutoGen	Framework multi-agents	REFUSÉ	-	Ne pas installer	Ancien choix Microsoft; runtime parallèle et trajectoire de maintenance moins favorable.	Consolidé
70	Agent Protocol	Protocole agent	REFUSÉ	-	Standardiser sur MCP + A2A + AG-UI	Ajoute un protocole sans capacité indispensable supplémentaire.	Consolidé
71	RootCX	Plateforme d'agents/applications	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Postgres + Keycloak + OpenBao + OPA + Harness + K3s.	Consolidé
72	AINative Studio	Plateforme IA	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Écosystème parallèle inférieur au stack FORGE spécialisé et gouverné.	Consolidé

4.3 Gateway modèles, serving et optimisation de contexte

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
73	Bifrost Gateway	Gateway LLM	ACCEPTÉ - CIBLE	3	Routeur/politiques -> Bifrost -> endpoints locaux/cloud	Gateway central haute performance pour routage, fallback, budgets et compatibilité API.	Consolidé
74	LiteLLM	Gateway LLM	REPLACÉ PAR BIFROST	-	Migration temporaire puis retrait	Fonctions couvertes; un seul gateway doit rester en production.	Consolidé
75	vLLM Semantic Router	Routeur sémantique	ACCEPTÉ	3	Interfaces/Hermes -> Semantic Router -> OPA/Bifrost	Choisit route/modèle selon tâche, coût, sécurité et disponibilité.	Consolidé
76	Aurelio Semantic Router	Routeur sémantique	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas vLLM Semantic Router dans le stack retenu.	Consolidé
77	RouteLLM	Routeur fort/faible	REFUSÉ	-	Ne pas installer	Trop limité face au routage multi-critères retenu.	Consolidé
78	premium_cost_gate	Service interne	ACCEPTÉ - NOYAU	3	OPA/OpenMeter -> gate -> Bifrost cloud	Applique quotas, budgets et approbations avant les modèles premium.	Consolidé
79	KubeAI	Gestionnaire d'endpoints modèles	ACCEPTÉ - NOYAU	3	K3s -> KubeAI -> vLLM/Ollama/autres runtimes	Placement GPU, pods, cache de modèles, autoscaling et endpoints Kubernetes.	Consolidé
80	vLLM	Moteur d'inférence	ACCEPTÉ - PRINCIPAL	3	KubeAI -> vLLM -> GPU	Serving principal pour modèles compatibles, haute concurrence et API standard.	Consolidé
81	SGLang	Moteur d'inférence	ACCEPTÉ - SPÉCIALISÉ	3	KubeAI -> SGLang -> modèles agentiques	Alternative performante pour structured outputs, cache de préfixe et workloads agentiques.	Consolidé
82	llama.cpp	Moteur d'inférence	ACCEPTÉ - FALLBACK	3	KubeAI/service -> llama.cpp -> GGUF/BC-250	Quantification GGUF, compatibilité large et matériel atypique.	Consolidé
83	Ollama	Runtime simple	ACCEPTÉ	3	KubeAI -> Ollama -> petits modèles/GGUF	Déploiement simple, BC-250, tests et dépannage; non exposé directement.	Consolidé
84	NVIDIA NIM	Serving optimisé NVIDIA	ACCEPTÉ - SPÉCIALISÉ	3	NIM Operator/K3s -> modèles supportés -> Bifrost	À utiliser seulement lorsque le gain mesuré justifie licence et dépendance NVIDIA.	Consolidé
85	TensorRT-LLM direct	Moteur d'inférence	REFUSÉ COMME COUCHE DIRECTE	-	Utilisé indirectement via NIM si nécessaire	Trop spécialisé et opérationnellement redondant avec vLLM/SGLang/NIM.	Consolidé
86	vLLM Production Stack	Stack Kubernetes vLLM	REFUSÉ COMME COUCHE PARALLÈLE	-	Fonctions absorbées par KubeAI + vLLM	Éviter un deuxième control plane de serving sur K3s.	Consolidé
87	NVIDIA AI Workbench	Atelier de développement	ACCEPTÉ - DEV	11	Poste principal -> prototypes/images -> Git/Harness	Bon pour environnements reproductibles et tests, pas pour gérer la flotte de production.	Consolidé
88	OpenRouter	Agrégateur cloud	ACCEPTÉ - FALLBACK	3	Bifrost -> OpenRouter -> fournisseurs secondaires	Fallback et accès à modèles additionnels; données sensibles interdites sans politique.	Consolidé
89	Headroom	Compression de contexte	ACCEPTÉ	3	Logs/RAG/MCP -> Headroom -> contexte modèle	Réduit contexte avant injection, avec politiques de conservation de la preuve.	Consolidé
90	llmtrim	Compression de contexte	REFUSÉ	-	Ne pas installer	Moins mature et ne surclasse pas Headroom.	Consolidé
91	LLMLingua-2	Compression de prompts	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ajoute un modèle de compression et ne surclasse pas Headroom pour l'usage global.	Consolidé
92	local-llm-autotune	Autotuning local	REFUSÉ	-	Ne pas installer	Projet trop jeune; tuning géré dans KubeAI/runtimes et benchmarks FORGE.	Consolidé
93	Cortex / Jan Server	Serveur local IA	REFUSÉ	-	Ne pas installer	Ne surclasse pas KubeAI + runtimes + Open WebUI.	Consolidé
94	LMCache	KV-cache distribué	ACCEPTÉ - SPÉCIALISÉ	3	vLLM/llm-d -> cache KV partagé	Réduit recomputation et accélère longues conversations/missions répétitives.	Consolidé
95	llm-d	Serving distribué	ACCEPTÉ - ÉVOLUTION	3	K3s -> llm-d/LMCache -> vLLM	À ajouter lorsque la flotte multi-nœuds justifie routage KV-aware et désagrégation.	Consolidé
96	March Trie KV-cache	Concept de cache	REPLACÉ	-	Remplacé par LMCache/llm-d	Solution opérationnelle moins mûre que les composants retenus.	Consolidé

4.4 RAG, recherche, graphes et intelligence du code

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
97	Qdrant	Base vectorielle	ACCEPTÉ - NOYAU	1	Ingestion/retrieval -> Qdrant -> agents	Base principale dense+sparse+hybride, filtres, multivecteurs et requêtes multi-étages.	Consolidé
98	pgvector	Extension PostgreSQL	ACCEPTÉ - COMPLÉMENTAIRE	1	PostgreSQL -> vecteurs métier/mémoire	Vecteurs transactionnels liés aux jointures, ACL et données métier.	Consolidé
99	Neo4j	Base graphe	ACCEPTÉ - SPÉCIALISÉ	1	Graphiti/code graph -> Neo4j -> agents	Knowledge graph, relations, dépendances, permissions et GraphRAG ciblé.	Consolidé
100	Weaviate	Base vectorielle	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Qdrant dans le rôle principal et créerait une base parallèle.	Consolidé
101	Docling	Parsing documentaire	ACCEPTÉ - NOYAU	4	Documents -> Docling -> pipeline d'ingestion	Extrait structure, tableaux, formules, code et ordre de lecture.	Consolidé
102	Crawl4AI	Crawler local	ACCEPTÉ - PRINCIPAL	4	Web -> Crawl4AI -> normalisation/ingestion	Crawler self-hosted principal pour documentation et sites accessibles.	Consolidé
103	Firecrawl	Crawler premium/fallback	ACCEPTÉ	4	Sites complexes -> Firecrawl -> ingestion	Complète Crawl4AI pour JavaScript, anti-bot et extraction structurée.	Consolidé
104	LlamaIndex	Framework d'ingestion	ACCEPTÉ - RÔLE LIMITÉ	4	Sources -> LlamaIndex transformations -> Qdrant	Connecteurs et ingestion hors ligne; pas runtime d'agents en production.	Consolidé
105	Haystack	Framework RAG/agents	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas LlamaIndex pour ingestion + LangGraph pour orchestration.	Consolidé
106	Tree-sitter	Parseur AST	ACCEPTÉ - NOYAU CODE	4	Dépôts -> Tree-sitter -> cAST/graphes	Analyse structurelle multi-langages pour chunking et dépendances.	Consolidé
107	cAST / chunking AST	Méthode de chunking	ACCEPTÉ - PRINCIPAL CODE	4	Tree-sitter -> chunks fonctions/classes -> Qdrant	Remplace le découpage naïf du code et préserve les frontières sémantiques.	Consolidé
108	Contextual Retrieval	Méthode RAG	ACCEPTÉ - SÉLECTIF	4	Chunks importants -> contexte enrichi -> Qdrant	Améliore récupération des documents critiques; activation selon gain mesuré.	Consolidé
109	BM25 + dense + RRF	Stratégie retrieval	ACCEPTÉ - NOYAU	4	Qdrant Query API -> fusion hybride -> reranker	Combine rappel lexical et sémantique avec fusion robuste.	Consolidé
110	hybrid_retrieve.py	Script interne	REPLACÉ	-	Conserver comme test seulement	La Query API native Qdrant est plus robuste pour la production.	Consolidé
111	Qwen3 Embedding	Famille embeddings	ACCEPTÉ - PRINCIPAL	4	Ingestion/requête -> embeddings -> Qdrant	Choix qualité multilingue/code; 0.6B rapide, 4B standard, 8B critique.	Consolidé
112	Qwen3 Reranker	Famille reranking	ACCEPTÉ - PRINCIPAL	4	Top-K Qdrant -> reranker -> contexte final	Reranker qualité; tailles adaptées au coût et à la criticité.	Consolidé
113	BGE-M3	Embedding hybride	ACCEPTÉ - SECONDAIRE	4	Pipeline alternatif -> dense+sparse+ColBERT	Option hybride multilingue et fallback; Qwen3 reste voie principale qualité.	Consolidé
114	BGE Reranker v2-m3	Reranker local	ACCEPTÉ - RAPIDE	4	PC2/GPU/CPU -> rerank rapide	Voie économique et fallback lorsque Qwen3 Reranker est trop coûteux.	Consolidé
115	Cohere Rerank	Reranker cloud	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Excellent, mais ne justifie pas dépendance cloud face aux rerankers locaux retenus.	Consolidé
116	Nomic Embed v1.x	Embedding	REPLACÉ	-	Remplacé par Qwen3 Embedding	Couverture et contexte moins adaptés au stack cible actuel.	Consolidé
117	Blockify Semantic Chunker	Service propriétaire	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Docling + chunking hiérarchique/cAST et manque de validation indépendante.	Consolidé
118	Graphify	Graphe de code/projet	ACCEPTÉ	4	Code/artefacts -> Graphify -> Neo4j/Qdrant	Graphe multimodal opérationnel et pont vers le contexte de projet.	Consolidé
119	Gortex	Graphe/analyse code	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Capacités fortes, mais risque mémoire/OOM mesuré supérieur à Graphify.	Consolidé
120	CodeGraph	Graphe de code	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Couverture observée insuffisante par rapport à Graphify/Sourcegraph/Tree-sitter.	Consolidé

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
121	Sourcegraph	Code search/intelligence	ACCEPTÉ - NOYAU CODE	4	Dépôts -> Sourcegraph -> agents/RAG	Recherche et navigation multi-dépôts; contexte précis pour agents de code.	Consolidé
122	Meilisearch	Moteur de recherche	REFUSÉ	-	Ne pas installer	Ne surclasse ni Qdrant pour RAG, ni Sourcegraph pour code.	Consolidé
123	OpenSearch pour RAG	Moteur recherche	REFUSÉ	-	Ne pas installer	Complexité trop élevée; Qdrant couvre retrieval et Loki couvre logs.	Consolidé
124	Jina Reader	Extraction Web	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Le duo Crawl4AI + Firecrawl couvre mieux les besoins locaux et complexes.	Consolidé
125	GraphRAG	Méthode	ACCEPTÉ - CIBLÉ	4	Neo4j/Graphiti -> retrieval graphe -> agents	Utiliser seulement si une ontologie et des relations apportent un gain mesuré.	Consolidé
126	OpenMetadata	Catalogue/ gouvernance données	ACCEPTÉ	4	Sources de données -> OpenMetadata -> ContextForge/agents	Catalogue, lineage, qualité, contrats et contexte de données self-hosted.	Consolidé
127	Atlan	Catalogue de données SaaS	REFUSÉ APRÈS COMPARAISON	-	Remplacé par OpenMetadata	Moins local-first et plus dépendant du SaaS/licence pour le control plane.	Consolidé
128	ZeroDB	Backend IA cloud unifié	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Qdrant + PostgreSQL + NATS + MinIO + mémoire spécialisée.	Consolidé

4.5 Mémoire agentique et apprentissage

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
129	MemOS 2.0	Runtime mémoire	ACCEPTÉ - PRINCIPAL	5	Forge Memory MCP -> MemOS -> Postgres/Qdrant	Runtime multi-agent pour souvenirs, outils, personas, multimodal et partage contrôlé.	Revalider version/licence
130	EverOS	Mémoire Markdown	ACCEPTÉ - MIROIR CANONIQUE	5	MemOS/Graphiti -> export Markdown/Git	Mémoire portable, lisible et récupérable; ne décide pas à la place du runtime.	Consolidé
131	EverMind / EverMemOS	Écosystème/ concepts mémoire	FUSIONNÉ DANS EVEROS	5	Concepts absorbés dans EverOS	Éviter un service séparé; conserver les principes d'auto-organisation utiles.	Consolidé
132	Mem0 local	Runtime mémoire	REPLACÉ PAR MEMOS	-	Migrer puis arrêter	MemOS est retenu comme runtime principal plus large pour l'infrastructure multi-agent.	Consolidé
133	Mem0 Pro	Mémoire cloud gérée	REFUSÉ APRÈS RÉÉVALUATION	-	Ne pas installer	Ajoute dépendance cloud et doublon sans fonction indispensable face à MemOS/EverOS.	Consolidé
134	Graphiti	Graphe temporel mémoire	ACCEPTÉ - NOYAU	5	Forge Memory MCP -> Graphiti -> Neo4j	Gère évolution, remplacement, provenance et temporalité des faits.	Consolidé
135	LangMem	Mémoire procédurale	ACCEPTÉ - RÔLE LIMITÉ	5	LangGraph -> LangMem -> prompts/skills	Extrait enseignements et améliore procédures; ne remplace pas MemOS.	Consolidé
136	Projectmem	Mémoire développement event-sourced	ACCEPTÉ - PRIORITAIRE	5	Git hooks/MCP -> Projectmem -> agents code	Mémorise problèmes, essais, erreurs et corrections pour éviter les répétitions.	Consolidé
137	Letta	Runtime d'agents stateful	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Hermes + LangGraph + MemOS et créerait un control plane parallèle.	Consolidé
138	Zep	Mémoire plateforme	REFUSÉ	-	Ne pas installer	Stratégie open source moins adaptée et doublon avec Graphiti/MemOS.	Consolidé
139	Cognee	Mémoire graph-vector	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas MemOS + Graphiti + Qdrant pour l'architecture retenue.	Consolidé
140	MemoryOS (BAI-LAB)	Mémoire conversationnelle	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Plus étroite que MemOS pour multi-agent et gouvernance FORGE.	Consolidé
141	MemPalace	Mémoire locale verbatim	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	EverOS couvre mieux la mémoire lisible/versionnable et MemOS le runtime.	Consolidé
142	MemoryLake	Plateforme mémoire cloud	REFUSÉ	-	Ne pas installer	Ne surclasse pas le stack local, gouverné et vérifiable.	Consolidé
143	infinity-context	Mémoire/context engine	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Projectmem + Context Pack Compiler couvrent mieux les besoins Git et review-gated.	Consolidé
144	Experience Learning YAML	Format interne ancien	REPLACÉ	-	Migrer vers Projectmem + LangMem	Éviter un fichier parallèle difficile à interroger et gouverner.	Consolidé
145	Cache sémantique LiteLLM-Qdrant	Cache	REPLACÉ	-	Utiliser cache exact Bifrost, puis mesurer	Dépendait de LiteLLM; cache sémantique à réintroduire seulement après preuves de fiabilité.	Consolidé
146	Forgetful	Mémoire MCP	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Redondant avec MemOS/EverOS/Graphiti/Projectmem.	Consolidé
147	Recall MCP	Mémoire Valkey	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Redondant avec le stack mémoire et ajoute une représentation parallèle.	Consolidé

4.6 MCP, protocoles et accès aux outils

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
148	ContextForge	Gateway MCP/A2A/API	ACCEPTÉ - NOYAU	7	Tous cockpits/agents -> ContextForge -> outils	Registre, proxy, auth, quotas et observabilité uniques pour outils et agents.	Consolidé
149	MCP	Protocole	ACCEPTÉ - NOYAU	7	Agents -> ContextForge -> outils/ressources	Standard agent-vers-outil; serveurs allowlistés et versionnés.	Consolidé
150	A2A	Protocole	ACCEPTÉ	7	Hermes -> agents distants indépendants	Communication agent-vers-agent; pas pour les simples appels internes.	Consolidé
151	AG-UI	Protocole UI-agent	ACCEPTÉ	7	Interfaces -> événements/état/streaming agents	Synchronise expérience utilisateur, état et actions humaines.	Consolidé
152	GitHub MCP officiel	Serveur MCP	ACCEPTÉ	7	ContextForge -> GitHub read/PR/issue	Accès dépôts/issues/PR; permissions minimales et écritures gated.	Consolidé
153	Filesystem MCP / forge-code-filessystem	Serveur MCP	ACCEPTÉ	7	ContextForge -> dépôts autorisés	Lecture seule par défaut; écriture uniquement branche/sandbox, jamais secrets ou racine.	Consolidé
154	Kubernetes MCP / forge-infra-kubernetes	Serveur MCP	ACCEPTÉ SOUS CONDITIONS	7	ContextForge -> ServiceAccount RBAC read-only -> K3s	Diagnostic K3s; remplacer implémentation actuelle par serveur avec read-only explicite.	Consolidé
155	Firecrawl MCP	Serveur MCP	ACCEPTÉ	7	ContextForge -> Firecrawl	Expose crawling et extraction Web aux agents.	Consolidé
156	Forge Memory MCP	Gateway interne mémoire	ACCEPTÉ - NOYAU	5	Agents -> ContextForge -> MemOS/Graphiti/Projectmem	Interface unique vers toutes les couches mémoire.	Consolidé
157	CodeTree MCP / forge-code-codetree	Serveur MCP	ACCEPTÉ	7	ContextForge -> AST/graphes code	Requêtes structurelles sur appels, dépendances et impacts du code.	Consolidé
158	Grafana MCP	Serveur MCP	ACCEPTÉ	7	ContextForge -> Grafana read-only	Lecture métriques, alertes, logs et traces; modifications gated.	Consolidé
159	Brave Search MCP	Serveur MCP	ACCEPTÉ	7	ContextForge -> recherche Web	Trouve les sources; Firecrawl/Crawl4AI extraient ensuite le contenu.	Consolidé
160	Playwright MCP	Serveur MCP	ACCEPTÉ SOUS CONDITIONS	7	ContextForge -> navigateur jetable sandboxé	Navigation et tests E2E avec domaines allowlistés, profil temporaire et gates externes.	Consolidé
161	Qdrant MCP officiel	Serveur MCP	ACCEPTÉ	7	ContextForge -> collections Qdrant autorisées	Recherche sémantique en lecture; écriture/suppression gated.	Consolidé
162	Git MCP officiel	Serveur MCP	ACCEPTÉ SOUS CONDITIONS	7	ContextForge -> dépôt unique -> branche isolée	Version épinglée, chemins validés, lecture par défaut et push gated.	Consolidé
163	E2B	Sandbox cloud	ACCEPTÉ - COMPLÉMENTAIRE	7	Agents -> E2B temporaire -> code non fiable	Sandbox cloud isolée pour code et MCP éphémères; aucune donnée sensible sans politique.	Consolidé
164	Stripe MCP	Serveur MCP sensible	ACCEPTÉ SOUS GATE	7	ContextForge -> Stripe compte limité	Lecture profilée; paiements, remboursements et modifications sous Nathan Gate.	Consolidé
165	Figma MCP	Serveur MCP	ACCEPTÉ	7	ContextForge -> Figma -> design-to-code	Expose designs, variables et composants; écriture gated.	Consolidé
166	Desktop Commander	Serveur MCP privilégié	REFUSÉ	-	Ne pas installer	Surface terminal/processus/fichiers trop large et couverte par outils sandboxés.	Consolidé
167	kubectl apply direct	Action privilégiée	REFUSÉ	-	Agent -> Git -> Harness -> Argo CD	Aucune écriture directe en production depuis un agent.	Consolidé
168	MCP access profiles	Politiques	ACCEPTÉ - RECLASSÉ	7	OPA -> profils filesystem-read/git-read/git-write	Ce sont des profils de permissions, pas des briques distinctes.	Consolidé
169	Claudesidian MCP	Serveur MCP Obsidian	REFUSÉ	-	Ne pas installer	Obsidian n'est pas canonique et chevauche EverOS/RAG/filesystem.	Consolidé
170	GPT Researcher MCP	Agent/recherche MCP	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas DeerFlow + Brave + Firecrawl + LangGraph.	Consolidé
171	Sequential Thinking MCP	Serveur de raisonnement	REFUSÉ	-	Ne pas installer	Ajoute appels/tokens sans capacité externe indispensable.	Consolidé
172	Reference MCP servers: Memory	Serveur exemple	REFUSÉ	-	Ne pas installer	Redondant avec Forge Memory MCP et stack mémoire.	Consolidé

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
173	Reference MCP servers: SQLite	Serveur exemple	REFUSÉ	-	Ne pas installer	PostgreSQL est canonique; éviter une base parallèle.	Consolidé
174	Reference MCP servers: Fetch	Serveur exemple	REFUSÉ	-	Ne pas installer	Couvert par Brave, Firecrawl, Crawl4AI et Playwright.	Consolidé

4.7 Sécurité, guardrails, identité et sandbox

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
175	OPA / Rego	Policy engine	ACCEPTÉ - AUTORITÉ	1	Tous plans/actions -> OPA -> allow/deny/human_gate	Décision déterministe finale; aucun LLM ne remplace cette autorité.	Consolidé
176	GA Guard	Classificateur safety	ACCEPTÉ SOUS CONDITIONS	8	Entrées/traces longues -> GA Guard -> score OPA	Détection sécurité longue durée; licence et performances à revalider avant production.	Revalider projet/licence
177	Lakera Guard	Firewall prompt injection	ACCEPTÉ - PREMIUM	8	Entrées/RAG/outils -> Lakera -> OPA	Défense spécialisée contre injections, exfiltration et contenus hostiles.	Consolidé
178	Llama Guard	Classificateur local	ACCEPTÉ	8	Entrées/sorties texte-image -> Llama Guard	Modération locale et multimodale; signal, jamais autorité finale.	Consolidé
179	NeMo Guardrails	Rails conversationnels	ACCEPTÉ	8	Interface/agents -> rails -> LangGraph	Contrôle dialogues, thèmes, validations et transitions; complément d'OPA.	Consolidé
180	LlamaFirewall	Firewall IA	ACCEPTÉ	8	Prompts/RAG/code -> détection -> OPA	Défense contre injections et sorties dangereuses; compléter par scanners déterministes.	Consolidé
181	PromptGuard	Détection injection	ACCEPTÉ - COMPOSANT	8	Texte entrant -> classificateur -> score risque	Signal rapide local dans la défense en profondeur.	Consolidé
182	CodeShield	Analyse code généré	ACCEPTÉ - COMPOSANT	8	Code agent -> analyse -> Harness	Détecte patterns de code risqués avant exécution ou fusion.	Consolidé
183	Microsoft Presidio	PII detection/redaction	ACCEPTÉ - NOYAU	8	Données -> Presidio -> expurgation -> cloud/RAG	Détecte et masque données personnelles structurées avant exposition.	Consolidé
184	LLM Guard	Guardrail open source	REFUSÉ	-	Ne pas installer	Projet archivé/non maintenu et fonctions couvertes par stack actuel.	Consolidé
185	Rebuff	Détection prompt injection	REFUSÉ	-	Ne pas installer	Projet archivé/prototype; ne surclasse pas Lakera/LlamaFirewall/GA Guard.	Consolidé
186	Keycloak	IAM humain	ACCEPTÉ - NOYAU	1	Utilisateurs -> SSO/RBAC -> applications	Identité, SSO et rôles centralisés pour interfaces et services.	Consolidé
187	OpenBao	Secrets manager	ACCEPTÉ - NOYAU	1	Services -> identités -> secrets courts	Secrets centralisés, rotation et accès minimal; aucun secret dans prompts/mémoire.	Consolidé
188	SPIFFE/SPIRE	Identité workloads	ACCEPTÉ - ÉVOLUTION	1	Workloads K3s -> identités mTLS	Identité forte service-à-service lorsque le cluster devient multi-nœuds mature.	Consolidé
189	Kyverno	Admission Kubernetes	ACCEPTÉ	1	Manifests -> politiques admission -> K3s	Bloque images non signées, privilèges, configurations non conformes.	Consolidé
190	Cilium Network Policies	Sécurité réseau	ACCEPTÉ - NOYAU	1	K3s -> politiques réseau eBPF	Segmente agents, modèles, données et outils; deny-by-default pour zones sensibles.	Consolidé
191	gVisor	Sandbox conteneur	ACCEPTÉ	8	Code non fiable -> runtime gVisor	Isolation renforcée pour exécution d'outils et code généré.	Consolidé
192	Kata Containers	Sandbox microVM	ACCEPTÉ - SPÉCIALISÉ	8	Tâches très risquées -> microVM	Isolation plus forte pour workloads non fiables à haut risque.	Consolidé
193	Tetragon	Runtime security	ACCEPTÉ	8	Cilium/eBPF -> événements sécurité -> OTel	Détection runtime et visibilité processus/réseau dans K3s.	Consolidé
194	Trivy	Scanner sécurité	ACCEPTÉ - NOYAU	9	CI/manifests/images -> Trivy -> gate	Scanne images, dépendances, IaC et vulnérabilités.	Consolidé
195	Gitleaks	Détection secrets	ACCEPTÉ - NOYAU	9	Pre-commit/CI -> Gitleaks -> blocage	Empêche les secrets d'entrer dans Git et artefacts.	Consolidé
196	Cosign / Sigstore	Signature supply chain	ACCEPTÉ - NOYAU	9	Build -> signature -> admission Kyverno	Signe images/artefacts et vérifie provenance avant déploiement.	Consolidé

4.8 Observabilité, évaluation et FinOps

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
197	OpenTelemetry	Standard télémétrie	ACCEPTÉ - NOYAU	2	Tous services -> OTel SDK -> Collector	Corrèle traces, métriques et logs entre agents, modèles, MCP, données et K3s.	Consolidé
198	OpenTelemetry Collector	Pipeline télémétrie	ACCEPTÉ - NOYAU	2	OTel SDK -> Collector -> Tempo/Prometheus/Loki/Langfuse	Réception, traitement, filtrage et export centralisés.	Consolidé
199	Langfuse	Observabilité LLM/agents	ACCEPTÉ - NOYAU	2	Agents/gateways -> Langfuse	Traces, prompts, coûts, datasets, évaluations et qualité des missions.	Consolidé
200	Prometheus	Métriques	ACCEPTÉ - NOYAU	2	Exporters/services -> Prometheus	Collecte métriques systèmes, applications, modèles et K3s.	Consolidé
201	Grafana	Dashboards/alertes	ACCEPTÉ - NOYAU	2	Prometheus/Loki/Tempo -> Grafana	Vue opérateur unifiée et alertes.	Consolidé
202	Loki	Logs	ACCEPTÉ	2	Services/K3s -> Loki	Stockage et recherche des logs corrélés.	Consolidé
203	Tempo	Traces distribuées	ACCEPTÉ	2	OTel Collector -> Tempo	Traces interservices à grande échelle.	Consolidé
204	NVIDIA DCGM Exporter	Métriques GPU NVIDIA	ACCEPTÉ	2	GPU Operator -> Prometheus	Utilisation, mémoire, température, erreurs et santé GPU NVIDIA.	Consolidé
205	ROCm exporter	Métriques GPU AMD	ACCEPTÉ	2	Nœuds AMD -> Prometheus	Visibilité GPU AMD et capacité de corrélation avec les missions.	Consolidé
206	OpenMeter	Metering/quotas	ACCEPTÉ - NOYAU FINOPS	2	Bifrost/agents -> OpenMeter -> budgets/gates	Mesure tokens, coûts, quotas et consommation par modèle/agent/mission.	Consolidé
207	Weights & Biases	Expériences/registre modèles	ACCEPTÉ	11	Fine-tuning/benchmarks -> W&B	Suivi entraînements, sweeps, datasets, artefacts et modèles.	Consolidé
208	MLflow	Expériences/registre	REPLACÉ PAR W&B	-	Migrer artefacts utiles	Éviter deux registres d'expériences et modèles.	Consolidé
209	WhyLabs / whylogs / LangKit	Data/model monitoring	ACCEPTÉ	2	Pipelines/modèles -> profils -> alertes	Détecte dérive, qualité de données et anomalies en production.	Consolidé
210	Ragas	Évaluation RAG	ACCEPTÉ	9	Jeux de tests -> Ragas -> CI/Langfuse	Mesure fidélité, précision/rappel du contexte et factualité.	Consolidé
211	DeepEval	Évaluation agents/LLM	ACCEPTÉ	9	Tests -> DeepEval -> Harness CI	Évalue conversations, agents, outils et RAG au-delà des métriques Ragas.	Consolidé
212	Promptfoo	Régression/red team	ACCEPTÉ - NOYAU TEST	9	Prompts/modèles/guardrails -> matrice CI	Tests de régression, sécurité, comparaison de modèles et red teaming.	Consolidé
213	LangSmith	Observabilité/évaluation	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Langfuse + OTel + Promptfoo/Ragas pour self-hosting et cohérence.	Consolidé
214	Arize Phoenix	Observabilité/évaluation	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Bonne analyse, mais stack Langfuse/OTel/Ragas suffit sans doublon.	Consolidé
215	Braintrust	Évaluation/observabilité	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Langfuse + Promptfoo/DeepEval + Harness.	Consolidé
216	Datadog LLM Observability	SaaS observabilité	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Coût et doublon face au stack self-hosted complet.	Consolidé
217	Galileo AI	Évaluation/guardrails	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Fonctions couvertes par Langfuse, Ragas, Promptfoo et guardrails retenus.	Consolidé
218	Helicone	Gateway/observabilité	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Bifrost + Langfuse + OpenMeter.	Consolidé
219	Fiddler AI	Observabilité IA	REFUSÉ APRÈS COMPARAISON	-	Ne pas installer	Ne surclasse pas Langfuse + WhyLabs + OTel et ajoute une plateforme propriétaire.	Consolidé
220	SWE-bench / SWE-bench Verified	Benchmark	ACCEPTÉ	11	Agents code -> benchmark isolé -> W&B	Mesure réparation logicielle sur cas standardisés; jamais seul critère.	Consolidé
221	Terminal-Bench	Benchmark	ACCEPTÉ	11	Agents terminal -> benchmark -> W&B	Évalue exécution terminal et autonomie opérationnelle.	Consolidé
222	AGBenchmark	Benchmark	ACCEPTÉ - EXTRAIT	11	Benchmark indépendant, sans AutoGPT runtime	Conserver comme test potentiel; ne nécessite pas la	Consolidé

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
		AutoGPT				plateforme AutoGPT.	

4.9 Données, stockage et messagerie

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
223	PostgreSQL	Base relationnelle	ACCEPTÉ - NOYAU	1	Services/ledgers/mémoire -> PostgreSQL	Source transactionnelle canonique, ACL, métadonnées et états durables.	Consolidé
224	CloudNativePG	Opérateur PostgreSQL	ACCEPTÉ	1	K3s -> CloudNativePG -> PostgreSQL HA/backup	Gestion Kubernetes fiable des clusters PostgreSQL.	Consolidé
225	Valkey	Cache/clé-valeur	ACCEPTÉ - NOYAU	1	Services -> Valkey	Cache, sessions, rate limits, verrous et files légères sous licence ouverte.	Consolidé
226	Redis	Cache/clé-valeur	REFUSÉ APRÈS COMPARAISON	-	Remplacé par Valkey	Valkey couvre le besoin avec gouvernance/licence plus simple pour le noyau.	Consolidé
227	NATS JetStream	Bus événements	ACCEPTÉ - NOYAU	1	Agents/services -> NATS -> consommateurs	Bus léger, persistant, replay et request/reply pour orchestration distribuée.	Consolidé
228	Kafka	Streaming distribué	REFUSÉ POUR LE SOCLE	-	Ne pas installer maintenant	Complexité injustifiée pour le volume actuel; réévaluer seulement à très grande échelle.	Consolidé
229	RabbitMQ	Broker messages	REFUSÉ POUR LE SOCLE	-	Ne pas installer	NATS couvre les besoins; ajouter uniquement si une dépendance AMQP impose ce choix.	Consolidé
230	Redpanda	Streaming compatible Kafka	REFUSÉ POUR LE SOCLE	-	Ne pas installer	Ne justifie pas un second bus tant que NATS répond au besoin.	Consolidé
231	MinIO	Stockage objet	ACCEPTÉ - NOYAU	1	Artefacts/datasets/backups -> MinIO	Stockage S3 local versionné pour documents, modèles, preuves et datasets.	Consolidé
232	immudb	Base append-only vérifiable	ACCEPTÉ	2	Proof Ledger -> immudb	Intégrité cryptographique des preuves et événements critiques.	Consolidé

4.10 Infrastructure, Kubernetes, IaC et livraison

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
233	K3s	Orchestrateur Kubernetes	ACCEPTÉ - SOCLE	1	Nœuds -> K3s -> tous services	Socle local multi-nœuds léger et standard Kubernetes.	Consolidé
234	Ansible	Configuration des hôtes	ACCEPTÉ - PRIORITAIRE	0	Inventaire -> Ansible -> nœuds	Installation reproductible, durcissement, réseau et configuration OS.	Consolidé
235	Terraform / OpenTofu	Infrastructure as Code	ACCEPTÉ - PRIORITAIRE	0	Code IaC -> cloud/DNS/réseau/ressources	Provisionnement reproductible avec état distant chiffré et verrouillé.	Consolidé
236	StackGen	IaC autonome	ACCEPTÉ SOUS GATE	9	Hermes -> StackGen -> Git -> Harness -> Argo CD	Génère/refactorise IaC et détecte dérive; aucun apply sans plan et approbation.	Revalider offre/licence
237	MetalLB	Load balancer bare-metal	ACCEPTÉ	1	K3s Services LoadBalancer -> IP LAN	Expose proprement les services sur réseau local sans cloud LB.	Consolidé
238	Traefik	Ingress/Gateway	ACCEPTÉ - NOYAU	1	Internet/LAN -> Traefik -> services K3s	Reverse proxy, TLS, ingress et Gateway API.	Consolidé
239	Cilium + Hubble	CNI/observabilité réseau	ACCEPTÉ - CIBLE	1	K3s réseau -> Cilium/Hubble	Réseau eBPF, politiques, flux et visibilité; migration contrôlée depuis CNI actuel.	Consolidé
240	Argo CD	GitOps	ACCEPTÉ - NOYAU	9	Git -> Argo CD -> K3s	Déploiement déclaratif et réconciliation; seule voie normale vers production.	Consolidé
241	Helm	Packaging Kubernetes	ACCEPTÉ	1	Charts -> Argo CD/K3s	Packaging et paramètres reproductibles des services.	Consolidé
242	Kustomize	Overlay Kubernetes	ACCEPTÉ	1	Base manifests -> overlays environnements	Différencie dev/staging/prod sans dupliquer les manifests.	Consolidé
243	cert-manager	Certificats Kubernetes	ACCEPTÉ	1	Ingress/services -> cert-manager -> TLS	Automatise certificats et renouvellement.	Consolidé
244	External Secrets Operator	Synchronisation secrets	ACCEPTÉ	1	OpenBao -> ESO -> Secrets K3s	Injecte secrets courts sans les stocker en clair dans Git.	Consolidé
245	Velero	Backup Kubernetes	ACCEPTÉ	1	K3s/PVC -> Velero -> MinIO	Sauvegarde/restauration des ressources et volumes.	Consolidé
246	Longhorn	Stockage bloc Kubernetes	ACCEPTÉ - TRANSITOIRE	1	K3s -> Longhorn -> PVC	Simple pour petit cluster; remplacer si stockage dédié plus mature.	Consolidé
247	Rook-Ceph	Stockage distribué	ACCEPTÉ - FUTUR	1	Nœuds stockage dédiés -> Ceph -> K3s	À adopter seulement avec au moins trois vrais nœuds et capacité opérationnelle.	Consolidé
248	NVIDIA GPU Operator	Gestion GPU NVIDIA	ACCEPTÉ	1	K3s -> drivers/device plugins/DCGM	Cycle de vie GPU NVIDIA standardisé.	Consolidé
249	AMD GPU Operator/device plugins	Gestion GPU AMD	ACCEPTÉ	1	K3s -> ROCm/device plugins	Expose et observe les GPU AMD dans le cluster.	Consolidé
250	Harness.io	Software delivery control plane	ACCEPTÉ - PRINCIPAL	9	Git/CI -> Harness -> Argo CD/K3s	CI/CD, sécurité supply chain, approbations, chaos et gouvernance de release.	Consolidé
251	GitHub Actions	CI	RECLASSÉ - SECONDAIRE	9	GitHub -> tests simples -> Harness/Argo	Conserver pour intégrations simples; Harness reste contrôle principal.	Consolidé
252	FleetDM	Endpoint management	ACCEPTÉ	1	PC/nœuds -> FleetDM/osquery	Inventaire, conformité, vulnérabilités et gestion des endpoints hors Kubernetes.	Consolidé

4.11 Blueprints, starters et plateformes spécialisées

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
253	av/harbor	Catalogue/starter Docker	ACCEPTÉ - BANC D'ESSAI	10	Machine isolée -> essais -> décisions FORGE	Excellent pour découvrir/tester des services; pas socle de production K3s.	Consolidé
254	hwdsi2 self-hosted-ai-stack	Starter Docker	ACCEPTÉ - BLUEPRINT DE RESET	0	Extraire health checks/secrets/profils -> manifests FORGE	Référence de simplicité et sécurité; ne pas conserver Docker Compose comme autorité finale.	Consolidé
255	local-ai-packaged (colearn00)	Starter Docker	REFUSÉ COMME RUNTIME	-	Extraire workflows/configs seulement	Le stack K3s FORGE le surclasse; utile comme bibliothèque d'exemples.	Consolidé
256	Stack FORGE Clean Foundation	Blueprint interne	ACCEPTÉ - CIBLE	0	Ansible/Terraform -> K3s -> GitOps -> couches FORGE	Socle définitif de redémarrage propre, construit à partir des meilleurs patterns externes.	Consolidé
257	Unslot Studio	Atelier fine-tuning	ACCEPTÉ - DEV	11	Datasets -> Unslot -> W&B -> export modèles	Préparation, fine-tuning, évaluation et export; aucun serving production.	Consolidé
258	Sourcegraph Cody	Assistant code	REFUSÉ	-	Ne pas activer	Sourcegraph est retenu pour l'intelligence du code, mais Cody chevauche les cockpits agents.	Consolidé

4.12 Auto-amélioration et recherche expérimentale

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
259	Darwin Gödel Machine (DGM)	Moteur évolution agents	ACCEPTÉ - CONCEPT	12	Copies sandboxées -> mutations -> benchmarks -> PR	Approche fondatrice; ne jamais modifier directement la production.	Consolidé
260	Huxley-Gödel Machine (HGM)	Sélection évolutionnaire	ACCEPTÉ - BASELINE	12	Lignées d'agents -> HGM -> candidats prometteurs	Sélectionne les branches selon potentiel futur; baseline expérimentale.	Consolidé
261	Red Queen Gödel Machine (RQGM)	Coévolution agents/évaluateurs	ACCEPTÉ - CIBLE ÉVALUATION	12	Agents + évaluateurs -> coévolution -> tests indépendants	Réduit l'optimisation aveugle d'un benchmark fixe; sandbox obligatoire.	Revalider code/licence
262	HyperAgents / DGM-H	Méta-évolution	ACCEPTÉ SOUS CONDITIONS	12	Sandbox isolée -> DGM-H -> TDAD/benchmarks -> PR	Fait évoluer agent et mécanisme d'amélioration; jamais auto-déploiement et licence à vérifier.	Revalider code/licence

4.13 Modèles IA et routes - à ne pas compter comme briques

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
263	GLM-5.2	Modèle cloud	ACCEPTÉ - ARCHITECTE	3	Bifrost -> API Z.ai	Planification et architecture complexe.	Consolidé
264	DeepSeek V4 Pro	Modèle cloud	ACCEPTÉ - JUGE/CRITIQUE	3	Bifrost -> API DeepSeek	Revue critique, raisonnement et arbitrage indépendant.	Consolidé
265	Kimi K2.7 Code	Modèle cloud	ACCEPTÉ - CODE LONG	3	Bifrost -> API Kimi	Missions longues de génie logiciel et gros dépôts.	Consolidé
266	Qwen3-Coder-Next	Modèle local	ACCEPTÉ - CODE PRINCIPAL	3	KubeAI -> vLLM/SGLang	Codeur agentique local principal selon quantification/matériel.	Consolidé
267	Ornith 35B	Modèle local	ACCEPTÉ - CODE/CRITIQUE	3	KubeAI -> llama.cpp/SGLang	Code autonome local et critique de trajectoires.	Consolidé
268	Devstral Small 2 24B	Modèle local	ACCEPTÉ - CODE RAPIDE	3	KubeAI -> vLLM/SGLang	Corrections ciblées, outils et tâches rapides.	Consolidé
269	Codestral	Modèle local/cloud	ACCEPTÉ - FIM	3	IDE/Bifrost -> endpoint Codestral	Complétion, fill-in-the-middle et blocs de code; pas cerveau principal.	Consolidé
270	Magistral Small 24B	Modèle local	ACCEPTÉ - JUGE LOCAL	3	KubeAI -> endpoint juge	Raisonnement local indépendant et vérifiable.	Consolidé
271	Holo 3.1 9B	Modèle local vision/action	ACCEPTÉ - COMPUTER USE	3	OpenClaw/Playwright -> Holo	Contrôle visuel navigateur/desktop/mobile dans sandbox.	Consolidé
272	Mistral 24B / Mistral Small 4	Modèle local/cloud	ACCEPTÉ - GÉNÉRALISTE	3	Bifrost/KubeAI	Classification, synthèse, tool calling et tâches générales.	Consolidé
273	BGE-M3	Modèle embedding	VOIR SECTION RAG	4	Pipeline embeddings	Modèle, pas brique logicielle.	Consolidé
274	Qwen3 Embedding/Reranker	Modèles retrieval	VOIR SECTION RAG	4	Pipeline RAG	Familles de modèles, pas briques logicielles.	Consolidé
275	LongCat 2.0	Modèle cloud	CONSERVER COMME OPTION	3	Bifrost route optionnelle	Évaluer contre modèles premium; pas brique.	Consolidé
276	Gemini 3.1 Pro	Modèle cloud	OPTION PREMIUM	3	Bifrost route optionnelle	Modèle alternatif pour multimodal/raisonnement; pas brique.	Consolidé
277	Minimax M3	Modèle cloud	OPTION PREMIUM	3	Bifrost route optionnelle	Alternative à benchmarker; pas brique.	Consolidé
278	Composer 2.5	Modèle/service cloud	OPTION	3	Bifrost route optionnelle	Exécuteur spécialisé à comparer; pas brique.	Consolidé
279	Grok build / xAI executor	Modèle/service cloud	OPTION	3	Bifrost route optionnelle	Exécuteur cloud potentiel; pas brique.	Consolidé
280	Gemma 4 26B/31B	Modèles locaux	SECONDAIRES	3	KubeAI -> endpoint local	Alternatives locales; pas briques et ne pas multiplier les routes sans benchmark.	Consolidé
281	GPT-OSS 20B/120B	Modèles	OPTION	3	KubeAI/cloud selon poids	À benchmarker; pas briques.	Consolidé
282	Qwen2.5 Coder 1.5B	Petit modèle local	ACCEPTÉ - UTILITAIRE	3	BC-250/NPU/CPU	Classification, routage léger et tâches peu coûteuses.	Consolidé
283	Claude API / OpenAI API	Fournisseurs cloud	ACCEPTÉ SOUS POLITIQUE	3	Bifrost -> fournisseurs	Accès premium ponctuel; données sensibles et coûts gouvernés.	Consolidé
284	OpenRouter routes	Routes cloud	RECLASSÉ	3	Bifrost -> OpenRouter	Ce sont des routes/fournisseurs, pas des briques.	Consolidé
285	forge-rag-chat	Route interne	RECLASSÉ	6	Open WebUI -> route -> RAG	Service/route, pas brique.	Consolidé
286	forge-orchestrate-chat	Route interne	RECLASSÉ	6	Interface -> Hermes Orchestrator	Service/route, pas brique.	Consolidé
287	forge-super / forge-cloud-* / forge-lowpower / forge-nim-scheduler	Alias et routes	RECLASSÉ	3	Registre modèles/routes	Ne jamais compter comme briques installables distinctes.	Consolidé

4.14 Services internes FORGE et command center

#	Brique / élément	Type réel	Statut final	Phase	Où et comment brancher	Pourquoi / décision	Vérification
288	Forge Control Plane / ForgeControlPlane	Service interne	ACCEPTÉ - CIBLE	6	Hermes + OPA + ledgers + gateways	Control plane global des missions, capacités, budgets, états et gates.	Consolidé
289	Forge Command Center	Interface interne	ACCEPTÉ	7	API read-only -> tableau de bord -> actions gated	Vue consolidée sur état, modèles, agents, missions et preuves.	Consolidé
290	Control Center read-only backend	Service interne	ACCEPTÉ - PRIORITAIRE	2	Sources réelles -> API RO -> UI	Expose uniquement des données live vérifiées avant d'autoriser l'écriture.	Consolidé
291	Command Center modes FORGE/GRS/Hybrid	Fonction UI	ACCEPTÉ	7	UI -> filtres/profils	Sépare contexte développement, exploitation GRS et vue hybride.	Consolidé
292	Command Center tools catalog API	Service interne	ACCEPTÉ	7	ContextForge registry -> API catalogue -> UI	Montre outils, scopes, santé, propriétaires et politiques.	Consolidé
293	Command Center write switches	Fonction sensible	ACCEPTÉ SOUS GATE	7	UI -> OPA/Nathan Gate -> actions	Écriture désactivée par défaut, activée temporairement et auditée.	Consolidé
294	Control Center live status	Service interne	ACCEPTÉ	2	Probes live -> API -> UI	Remplace snapshots statiques par état mesuré et horodaté.	Consolidé

5. Liste finale classée par fonction

Gouvernance, méthodes, skills et preuves

Retenus / reclassés : current-state.yml / State Ledger [ACCEPTÉ - NOYAU]; Decision Ledger [ACCEPTÉ - NOYAU]; Proof Ledger [ACCEPTÉ - NOYAU]; Execution Ledger [ACCEPTÉ]; Model Ledger [ACCEPTÉ]; Artifact Ledger [ACCEPTÉ]; Supply-chain Ledger [ACCEPTÉ]; IAR-E PostgreSQL Ledger [ACCEPTÉ - NOYAU]; Nathan Gates [ACCEPTÉ - NOYAU]; Proof-Driven Agentic SDLC [ACCEPTÉ - NOYAU]; CIV Pattern [ACCEPTÉ]; BMAD [ACCEPTÉ]; GitHub Spec Kit [ACCEPTÉ]; Superpowers [ACCEPTÉ]; TDAD [ACCEPTÉ - PRIORITAIRE]; MetaGPT SOP [ACCEPTÉ - CONCEPT]; RARV / Loki-like [RECLASSÉ]; AGENTS.md [ACCEPTÉ - NOYAU]; memory-bank [ACCEPTÉ]; DO-NOT-FORGET / CANON [ACCEPTÉ]; ACTIVE_MEMORY_LOCKED_V5 [ACCEPTÉ - ARCHIVE]; audit-canon-skill [ACCEPTÉ - NOYAU]; no-fake-done-check [ACCEPTÉ - NOYAU]; forge-quality-phase-a-skill [ACCEPTÉ]; rag-retrieve-context [ACCEPTÉ]; Find Skills / Skill Registry [ACCEPTÉ]; skills-runtime-selection [ACCEPTÉ]; Karpathy Guidelines [ACCEPTÉ]; Matt Pocock Skills [ACCEPTÉ]; ACE Context Engineering [ACCEPTÉ]; Context Pack Compiler [ACCEPTÉ - NOYAU]; Sleep-time Consolidation [ACCEPTÉ]; DSPy [ACCEPTÉ - SPÉCIALISÉ]; GEPA [ACCEPTÉ - SPÉCIALISÉ].

Refusés après comparaison : GSD Core; NVIDIA-style skills / agency-persona-conversion.

Orchestration, agents et interfaces

Retenus / reclassés : Hermes Orchestrator [ACCEPTÉ - NOYAU]; Hermes Agent [ACCEPTÉ - NOYAU]; LangGraph [ACCEPTÉ - NOYAU]; n8n [ACCEPTÉ - NOYAU]; OpenClaw [ACCEPTÉ]; Open WebUI [ACCEPTÉ]; Dify [ACCEPTÉ - RÔLE LIMITÉ]; Mastra [ACCEPTÉ]; Vercel AI SDK [ACCEPTÉ - NOYAU TS]; Agentailor [ACCEPTÉ - BLUEPRINT]; Pydantic Deep Agents (Vstorm) [ACCEPTÉ - PRINCIPAL]; Vstorm Full-Stack AI Agent Template [ACCEPTÉ - BLUEPRINT]; OpenHands [ACCEPTÉ SOUS CONDITIONS]; Aider [ACCEPTÉ]; Cline [ACCEPTÉ]; Cursor [ACCEPTÉ]; VSCodium [ACCEPTÉ]; Claude Code [ACCEPTÉ - PREMIUM]; Codex CLI [ACCEPTÉ]; OpenCode [ACCEPTÉ]; DeerFlow 2.0 [ACCEPTÉ - SPÉCIALISÉ]; kagent [ACCEPTÉ - NOYAU K3S]; forge-council [ACCEPTÉ]; Atoms [ACCEPTÉ - EXTERNE].

Remplacés / fusionnés : LangChain DeepAgents [REPLACÉ]; MetaGPT X / MGX [REPLACÉ].

Refusés après comparaison : Vercel Eve; AutoGPT Platform; MetaGPT runtime; Google ADK; OpenAI Agents SDK; CrewAI; AutoGen; Agent Protocol; RootCX; AINative Studio.

Gateway modèles, serving et optimisation de contexte

Retenus / reclassés : Bifrost Gateway [ACCEPTÉ - CIBLE]; vLLM Semantic Router [ACCEPTÉ]; premium_cost_gate [ACCEPTÉ - NOYAU]; KubeAI [ACCEPTÉ - NOYAU]; vLLM [ACCEPTÉ - PRINCIPAL]; SGLang [ACCEPTÉ - SPÉCIALISÉ]; llama.cpp [ACCEPTÉ - FALLBACK]; Ollama [ACCEPTÉ]; NVIDIA NIM [ACCEPTÉ - SPÉCIALISÉ]; NVIDIA AI Workbench [ACCEPTÉ - DEV]; OpenRouter [ACCEPTÉ - FALLBACK]; Headroom [ACCEPTÉ]; LMCACHE [ACCEPTÉ - SPÉCIALISÉ]; llm-d [ACCEPTÉ - ÉVOLUTION].

Remplacés / fusionnés : LiteLLM [REPLACÉ PAR BIFROST]; March Trie KV-cache [REPLACÉ].

Refusés après comparaison : Aurelio Semantic Router; RouteLLM; TensorRT-LLM direct; vLLM Production Stack; llmtrim; LLMlingua-2; local-llm-autotune; Cortex / Jan Server.

RAG, recherche, graphes et intelligence du code

Retenus / reclassés : Qdrant [ACCEPTÉ - NOYAU]; pgvector [ACCEPTÉ - COMPLÉMENTAIRE]; Neo4j [ACCEPTÉ - SPÉCIALISÉ]; Docling [ACCEPTÉ - NOYAU]; Crawl4AI [ACCEPTÉ - PRINCIPAL]; Firecrawl [ACCEPTÉ]; LlamaIndex [ACCEPTÉ - RÔLE LIMITÉ]; Tree-sitter [ACCEPTÉ - NOYAU CODE]; cAST / chunking AST [ACCEPTÉ - PRINCIPAL CODE]; Contextual Retrieval [ACCEPTÉ - SÉLECTIF]; BM25 + dense + RRF [ACCEPTÉ - NOYAU]; Qwen3 Embedding [ACCEPTÉ - PRINCIPAL]; Qwen3 Reranker [ACCEPTÉ - PRINCIPAL]; BGE-M3 [ACCEPTÉ - SECONDAIRE]; BGE Reranker v2-m3 [ACCEPTÉ - RAPIDE]; Graphify [ACCEPTÉ]; Sourcegraph [ACCEPTÉ - NOYAU CODE]; GraphRAG [ACCEPTÉ - CIBLE]; OpenMetadata [ACCEPTÉ].

Remplacés / fusionnés : hybrid_retrieve.py [REPLACÉ]; Nomic Embed v1.x [REPLACÉ].

Refusés après comparaison : Weaviate; Haystack; Cohere Rerank; Blockify Semantic Chunker; Gortex; CodeGraph; Meilisearch; OpenSearch pour RAG; Jina Reader; Atlan; ZeroDB.

Mémoire agentique et apprentissage

Retenus / reclassés : MemOS 2.0 [ACCEPTÉ - PRINCIPAL]; EverOS [ACCEPTÉ - MIROIR CANONIQUE]; Graphiti [ACCEPTÉ - NOYAU]; LangMem [ACCEPTÉ - RÔLE LIMITÉ]; Projectmem [ACCEPTÉ - PRIORITAIRE].

Remplacés / fusionnés : EverMind / EverMemOS [FUSIONNÉ DANS EVEROS]; Mem0 local [REPLACÉ PAR MEMOS]; Experience Learning YAML [REPLACÉ]; Cache sémantique LiteLLM-Qdrant [REPLACÉ].

Refusés après comparaison : Mem0 Pro; Letta; Zep; Cognee; MemoryOS (BAI-LAB); MemPalace; MemoryLake; infinity-context; Forgetful; Recall MCP.

MCP, protocoles et accès aux outils

Retenus / reclassés : ContextForge [ACCEPTÉ - NOYAU]; MCP [ACCEPTÉ - NOYAU]; A2A [ACCEPTÉ]; AG-UI [ACCEPTÉ]; GitHub MCP officiel [ACCEPTÉ]; Filesystem MCP / forge-code-filessystem [ACCEPTÉ]; Kubernetes MCP / forge-infra-kubernetes [ACCEPTÉ SOUS CONDITIONS]; Firecrawl MCP [ACCEPTÉ]; Forge Memory MCP [ACCEPTÉ - NOYAU]; CodeTree MCP / forge-code-codetree [ACCEPTÉ]; Grafana MCP [ACCEPTÉ]; Brave Search MCP [ACCEPTÉ]; Playwright MCP [ACCEPTÉ SOUS CONDITIONS]; Qdrant MCP officiel [ACCEPTÉ]; Git MCP officiel [ACCEPTÉ SOUS CONDITIONS]; E2B [ACCEPTÉ - COMPLÉMENTAIRE]; Stripe MCP [ACCEPTÉ SOUS GATE]; Figma MCP [ACCEPTÉ]; MCP access profiles [ACCEPTÉ - RECLASSÉ].

Refusés après comparaison : Desktop Commander; kubectl apply direct; Claudesidian MCP; GPT Researcher MCP; Sequential Thinking MCP; Reference MCP servers: Memory; Reference MCP servers: SQLite; Reference MCP servers: Fetch.

Sécurité, guardrails, identité et sandbox

Retenus / reclassés : OPA / Rego [ACCEPTÉ - AUTORITÉ]; GA Guard [ACCEPTÉ SOUS CONDITIONS]; Lakera Guard [ACCEPTÉ - PREMIUM]; Llama Guard [ACCEPTÉ]; NeMo Guardrails [ACCEPTÉ]; LlamaFirewall [ACCEPTÉ]; PromptGuard [ACCEPTÉ - COMPOSANT]; CodeShield [ACCEPTÉ - COMPOSANT]; Microsoft Presidio [ACCEPTÉ - NOYAU]; Keycloak [ACCEPTÉ - NOYAU]; OpenBao [ACCEPTÉ - NOYAU]; SPIFFE/SPIRE [ACCEPTÉ - ÉVOLUTION]; Kyverno [ACCEPTÉ]; Cilium Network Policies [ACCEPTÉ - NOYAU]; gVisor [ACCEPTÉ]; Kata Containers [ACCEPTÉ - SPÉCIALISÉ]; Tetragon [ACCEPTÉ]; Trivy [ACCEPTÉ - NOYAU]; Gitleaks [ACCEPTÉ - NOYAU]; Cosign / Sigstore [ACCEPTÉ - NOYAU].

Refusés après comparaison : LLM Guard; Rebuff.

Observabilité, évaluation et FinOps

Retenus / reclassés : OpenTelemetry [ACCEPTÉ - NOYAU]; OpenTelemetry Collector [ACCEPTÉ - NOYAU]; Langfuse [ACCEPTÉ - NOYAU]; Prometheus [ACCEPTÉ - NOYAU]; Grafana [ACCEPTÉ - NOYAU]; Loki [ACCEPTÉ]; Tempo [ACCEPTÉ]; NVIDIA DCGM Exporter [ACCEPTÉ]; ROCm exporter [ACCEPTÉ]; OpenMeter [ACCEPTÉ - NOYAU FINOPS]; Weights & Biases [ACCEPTÉ]; WhyLabs / whylogs / LangKit [ACCEPTÉ]; Ragas [ACCEPTÉ]; DeepEval [ACCEPTÉ]; Promptfoo [ACCEPTÉ - NOYAU TEST]; SWE-bench / SWE-bench Verified [ACCEPTÉ]; Terminal-Bench [ACCEPTÉ]; AGBenchmark [ACCEPTÉ - EXTRAIT].

Remplacés / fusionnés : MLflow [REPLACÉ PAR W&B].

Refusés après comparaison : LangSmith; Arize Phoenix; Braintrust; Datadog LLM Observability; Galileo AI; Helicone; Fiddler AI.

Données, stockage et messagerie

Retenus / reclassés : PostgreSQL [ACCEPTÉ - NOYAU]; CloudNativePG [ACCEPTÉ]; Valkey [ACCEPTÉ - NOYAU]; NATS JetStream [ACCEPTÉ - NOYAU]; MinIO [ACCEPTÉ - NOYAU]; immudb [ACCEPTÉ].

Refusés après comparaison : Redis; Kafka; RabbitMQ; Redpanda.

Infrastructure, Kubernetes, IaC et livraison

Retenus / reclassés : K3s [ACCEPTÉ - SOCLE]; Ansible [ACCEPTÉ - PRIORITAIRE]; Terraform / OpenTofu [ACCEPTÉ - PRIORITAIRE]; StackGen [ACCEPTÉ SOUS GATE]; MetalLB [ACCEPTÉ]; Traefik [ACCEPTÉ - NOYAU]; Cilium + Hubble [ACCEPTÉ - CIBLE]; Argo CD [ACCEPTÉ - NOYAU]; Helm [ACCEPTÉ]; Kustomize [ACCEPTÉ]; cert-manager

[ACCEPTÉ]; External Secrets Operator [ACCEPTÉ]; Velero [ACCEPTÉ]; Longhorn [ACCEPTÉ - TRANSITOIRE]; Rook-Ceph [ACCEPTÉ - FUTUR]; NVIDIA GPU Operator [ACCEPTÉ]; AMD GPU Operator/device plugins [ACCEPTÉ]; Harness.io [ACCEPTÉ - PRINCIPAL]; GitHub Actions [RECLASSÉ - SECONDAIRE]; FleetDM [ACCEPTÉ].

Blueprints, starters et plateformes spécialisées

Retenus / reclassés : av/harbor [ACCEPTÉ - BANC D'ESSAI]; hwdsl2 self-hosted-ai-stack [ACCEPTÉ - BLUEPRINT DE RESET]; Stack FORGE Clean Foundation [ACCEPTÉ - CIBLE]; Unsloth Studio [ACCEPTÉ - DEV].

Refusés après comparaison : local-ai-packaged (colearn00); Sourcegraph Cody.

Auto-amélioration et recherche expérimentale

Retenus / reclassés : Darwin Gödel Machine (DGM) [ACCEPTÉ - CONCEPT]; Huxley-Gödel Machine (HGM) [ACCEPTÉ - BASELINE]; Red Queen Gödel Machine (RQGM) [ACCEPTÉ - CIBLE ÉVALUATION]; HyperAgents / DGM-H [ACCEPTÉ SOUS CONDITIONS].

Modèles IA et routes - à ne pas compter comme briques

Retenus / reclassés : GLM-5.2 [ACCEPTÉ - ARCHITECTE]; DeepSeek V4 Pro [ACCEPTÉ - JUGE/CRITIQUE]; Kimi K2.7 Code [ACCEPTÉ - CODE LONG]; Qwen3-Coder-Next [ACCEPTÉ - CODE PRINCIPAL]; Ormith 35B [ACCEPTÉ - CODE/CRITIQUE]; Devstral Small 2 24B [ACCEPTÉ - CODE RAPIDE]; Codestral [ACCEPTÉ - FIM]; Magistral Small 24B [ACCEPTÉ - JUGE LOCAL]; Holo 3.1 9B [ACCEPTÉ - COMPUTER USE]; Mistral 24B / Mistral Small 4 [ACCEPTÉ - GÉNÉRALISTE]; BGE-M3 [VOIR SECTION RAG]; Qwen3 Embedding/Reranker [VOIR SECTION RAG]; LongCat 2.0 [CONSERVER COMME OPTION]; Gemini 3.1 Pro [OPTION PREMIUM]; Minimax M3 [OPTION PREMIUM]; Composer 2.5 [OPTION]; Grok build / xAI executor [OPTION]; Gemma 4 26B/31B [SECONDAIRES]; GPT-OSS 20B/120B [OPTION]; Qwen2.5 Coder 1.5B [ACCEPTÉ - UTILITAIRE]; Claude API / OpenAI API [ACCEPTÉ SOUS POLITIQUE]; OpenRouter routes [RECLASSÉ]; forge-rag-chat [RECLASSÉ]; forge-orchestrate-chat [RECLASSÉ]; forge-super / forge-cloud-* / forge-lowpower / forge-nim-scheduler [RECLASSÉ].

Services internes FORGE et command center

Retenus / reclassés : Forge Control Plane / ForgeControlPlane [ACCEPTÉ - CIBLE]; Forge Command Center [ACCEPTÉ]; Control Center read-only backend [ACCEPTÉ - PRIORITAIRE]; Command Center modes FORGE/GRS/Hybrid [ACCEPTÉ]; Command Center tools catalog API [ACCEPTÉ]; Command Center write switches [ACCEPTÉ SOUS GATE]; Control Center live status [ACCEPTÉ].

6. Règles finales de mise en œuvre

- Ne jamais installer plusieurs control planes pour la même fonction. Un seul gateway modèles, un seul gateway MCP, une seule autorité d'état et une seule voie de déploiement production.
- Aucune brique acceptée n'est « installée » tant qu'elle n'a pas : version épinglée, licence vérifiée, propriétaire, health check, test d'intégration, sauvegarde, rollback, métriques et preuve au ledger.
- Les modèles, routes, alias, profils de permissions et méthodes ne doivent plus être comptés comme briques logicielles.
- Les écritures production, paiements, secrets, réseau, suppressions et engagements externes restent sous Nathan Gate.
- Les composants expérimentaux DGM/HGM/RQGM/DGM-H travaillent uniquement sur des copies isolées et produisent des pull requests; ils ne modifient jamais la production directement.
- Le stack doit être réévalué par benchmark réel sur le matériel FORGE. Une brique nouvelle remplace l'ancienne uniquement si elle gagne sur qualité, sécurité, maturité, maintenance, coût et intégration globale.

Fin du catalogue maître. Ce document doit être versionné dans le dépôt FORGE ATLAS et relié au Decision Ledger.